Opis projektu z przedmiotu
Metody numeryczne dla stochastycznych równań różniczkowych

Julia Mierzyńska, Jolanta Sułkowska

Temat projektu:

"Estymacja rozwiązań równania Ornsteina-Uhlenbecka metodą Monte Carlo i analiza technik redukcji wariancji"

Opis projektu

Celem projektu jest **numeryczna aproksymacja stochastycznego równania różniczkowego** w modelu Hull-White'a przy użyciu **metody Monte Carlo** oraz analiza zbieżności jej rozwiązań.

Etapy:

1. **Dyskretyzacja i aproksymacja SDE:** Ciągłe SDE opisujące ewolucję stopy procentowej zostaje sprowadzone do postaci dyskretnej przy użyciu jawnego schematu Eulera-Maruyamy z krokiem czasowym Δt.

2. **Generowanie zbioru realizacji trajektorii procesu:** Za pomocą schematu aproksymacyjnego w pythonie generowana jest masowa liczba niezależnych, losowych trajektorii reprezentujących możliwe realizacje procesu Wienera.

3. **Estymacja Monte Carlo:** Wyznaczenie końcowej wartości oczekiwanej (czyli ceny instrumentu finansowego) poprzez obliczenie średniej ze wszystkich uzyskanych wyników.

Model

Podstawą modelu stóp procentowych Hull-White'a jest stochastyczny proces Ornsteina-Uhlenbecka, który opisuje krótkoterminową stopę procentową (*short rate*) powracającą do średniej. Równanie to ma postać:

$$dX_t = -aX_t dt + \sigma(t) dW_t, \tag{1}$$

gdzie a to prędkość powrotu do średniej, $\sigma(t)$ to funkcja zmienności, a dW_t to przyrost standardowego procesu Wienera.

Algorytm i Metodologia

W celu wyceny opcji oraz oceny dokładności uzyskanych wyników, w projekcie połączymy podejście symulacyjne z analizą teoretyczną:

1. **Symulacja Monte Carlo:** Wygenerowanie losowych trajektorii stopy procentowej w pythonie przy użyciu standardowej dyskretyzacji (schematu Eulera-Maruyamy), a następnie uśrednienie wyników wypłaty w celu wyznaczenia ceny opcji.

2. **Weryfikacja analityczna:** Wykorzystanie jawnego wzoru analitycznego Blacka dla modelu Hull-White'a jako dokładnego punktu odniesienia. Stąd obliczymy dokładny błąd symulacji.

Zastosowanie metody Monte Carlo i redukcja wariancji

Wycena opcji polega na generowaniu losowych scenariuszy rozwoju stóp procentowych i uśrednianiu uzyskanego wyniku. Zajmiemy się też analizą technik redukcji wariancji:

- **Metoda zmiennych antytetycznych:** uruchamianie symulacji parami — przy użyciu wygenerowanych przyrostów dW oraz ich lustrzanego odbicia $-dW$.

- **Metoda zmiennych kontrolnych:** Wykorzystanie dodatkowej zmiennej o znanej wartości oczekiwanej do skorygowania wyniku symulacji.

Zakres prac badawczych w Pythonie

1. **Zaimplementowanie wzorów jawnych:** Zaprogramowanie funkcji analitycznej (`PriceBondOption`), która posłuży do wyznaczenia dokładnej, teoretycznej ceny opcji (nasz punkt odniesienia).

2. **Stworzenie symulatora stóp procentowych:** Napisanie generatora odpowiedzialnego za tworzenie losowych trajektorii w modelu Hull-White'a.

3. **Algorytm kalibracji:** Zaimplementowanie procedury estymacji parametrów za pomocą biblioteki `scipy.optimize`, minimalizującej błąd między cenami teoretycznymi a rynkowymi.

4. **Wycena metodą Monte Carlo:** Wyznaczenie ceny opcji za pomocą klasycznego algorytmu Monte Carlo i obliczenie błędu względem wartości teoretycznej.

5. **Optymalizacja wariancji:** Zaimplementowanie metody redukowania wariancji i pokazanie, o ile mniejszy błąd statystyczny otrzymujemy w porównaniu do klasycznego podejścia.

Oczekiwane wyniki i analiza zbieżności

W projekcie spodziewamy się uzyskać konkretne rezultaty numeryczne, które pozwolą na zweryfikowanie poprawności implementacji oraz ocenę efektywności zastosowanych algorytmów. Oczekujemy, że wraz ze wzrostem liczby symulacji ($N \to \infty$), ceny opcji uzyskane metodą Monte Carlo będą asymptotycznie dążyć do tej samej wartości dokładnej. Stanowi to nasz główny test poprawności działania napisanego kodu. Spodziewamy się następujących właściwości zbieżności:

- Klasyczna metoda Monte Carlo powinna wykazać standardową teoretyczną zbieżność rzędu $\mathcal{O}(1/\sqrt{N})$.

- Zastosowany jawny schemat Eulera-Maruyamy wprowadza dodatkowy błąd dyskretyzacji czasowej (wynikający z kroku Δt). Silna zbieżność rzędu będzie widoczna przy analizie wpływu gęstości siatki czasowej na ostateczny błąd przybliżenia.

Efektywność technik redukcji wariancji

Wdrożenie metod redukcji wariancji ma na celu przyspieszenie zbieżności algorytmu.

- **Metoda zmiennych antytetycznych:** Spodziewamy się zauważalnego, około dwukrotnego zmniejszenia wariancji estymatora.
- **Metoda zmiennych kontrolnych:** Jako zmienną kontrolną planujemy wykorzystać wartość końcową stopy procentowej X_T. Spodziewamy się, że technika ta przyniesie znacznie silniejszy spadek wariancji niż metoda zmiennych antytetycznych.